B · WHERE

B．端云协同 Agent

从请求路由到步级协作、选择性披露与可信执行

A 决定何时并行　B 决定在哪里执行　C 决定执行什么
D 决定能否信任



端云矛盾不是二选一，而是多目标约束

- **左栏：**全本地
- **优点：**隐私、离线可用、无 API 费用、低网络依赖
- **缺点：**模型小、长轨迹脆弱、端侧 prefill/decode 慢
- **右栏：**全云端

- **优点：**推理和多模态能力强、工具生态成熟
- **缺点：**网络延迟、持续成本、原始 UI/ 本地数据暴露
- **底部结论：**协同的目标不是“尽量少用云”，而是在成功率约束下最小化云调用、延迟、通信与隐私暴露。

同叫“端云协同”，实际可能发生在四个不同层次

1 层次 1 任务层

云端分解，本地执行子任务（Minions）

2 层次 2 轨迹层

每个 Agent step 动态路由（Hera）

3 层次 3 表示层

只上传 UI block / feature / KV （CORE、split inference）

4 层次 4 执行层

本地过滤与守卫、云端语义判断（Cognitive Firewall、AgenTEE）

- **右下角提示：**比较论文前，必须先问“路由的单位是什么？”

B 方向代表论文：从协作协议走向可信 Agent runtime

- **时间线：** 2025 Minions → 2025 CORE → 2026 Mobile-Agent-v3.5 → 2026 Hera → 2026 Agent-X / AgenTEE / Cognitive Firewall
- **主讲种子：** Hera 、 CORE

- **补充桥梁：** Minions 、 Agent-X 、 Mobile-Agent-v3.5 、 AgenTEE 、 Cognitive Firewall
- **阅读问题：** 谁决定？传什么？何时上云？如何证明收益与安全？

Minions：让云端“指导”，而不是让云端读取全部本地上下文

- **问题：**本地小模型能读私有长文档，但复杂推理弱；云端强模型能力高，却不应接收全文。
- **Naive Minion：**本地与云端来回对话；远程成本降 30.4×，但仅恢复 87% cloud-only 性能。

- **失败原因：**本地模型难以执行复杂多步指令，也难以在长上下文中稳定推理。
- **转折：**把难任务拆成短、局部、可并行的子任务。