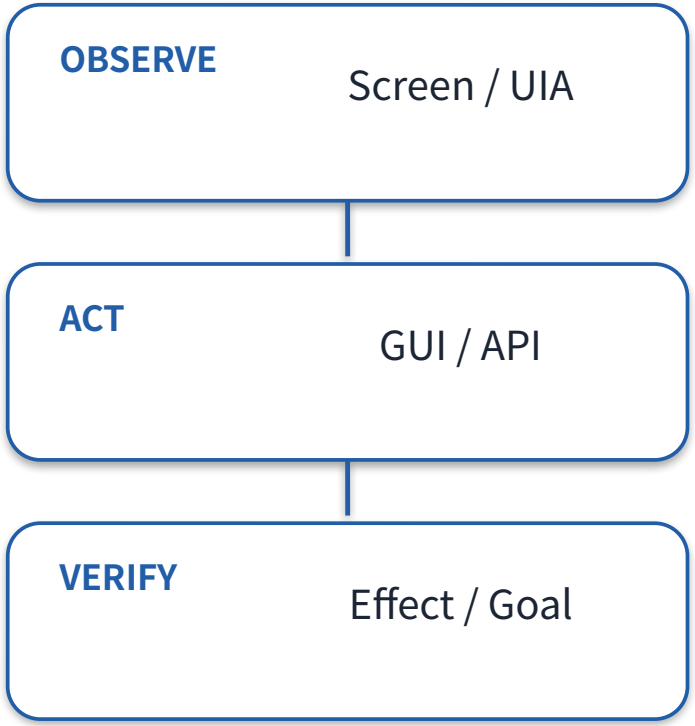
C • WHAT

C． GUI Agent 执行

从可执行环境、 OS 级系统到执行前 / 中 / 后的验证闭环

A 决定何时并行　B 决定在哪里执行　C 决定执行什么
D 决定能否信任



一次错误会改变环境，并沿后续轨迹持续放大

- **离线任务：**输出错误通常只影响当前答案。
- **GUI 任务：** click/type/delete/pay 会改变真实系统状态；错误可能不可逆。

- **额外挑战：**像素 / 控件 grounding 、动态渲染、网络延迟、弹窗、跨应用状态、隐藏系统状态。
- **核心指标：**不能只看单步 action accuracy ，必须看 end-to-end success 、 loop 、 recovery 和副作用。

GUI Agent 是“感知—规划—动作—验证”的完整系统

- **Observation：** screenshot / DOM / a11y / UIA / XML 。
- **Grounding：** element / coordinate / control / text 。
- **Planning：** task → subgoal → candidate actions 。
- **Execution：** GUI event / keyboard / shell / API / MCP 。
- **Verification：** action effect / hidden state / artifact / completion condition 。
- **Recovery：** retry / re-ground / alternative action / rollback / ask user 。

本章从环境与 Actor，走向三阶段 verifier

- **环境底座：** OSWorld 。
- **执行系统：** UFO² 。
- **跨平台 Actor：** Mobile-Agent-v3.5 / GUI-Owl-1.5 。
- **端云移动场景：** CORE 。

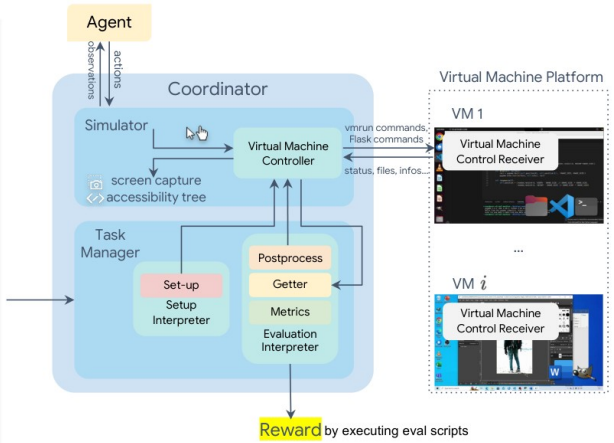
- **执行前：** GUI-Critic-R1 。
- **执行中：** VeriGUI 。
- **执行后：** VAGEN / IRA 。

静态截图数据无法评估替代路径、状态变化与跨应用执行

- **现有问题：**离线 demonstration 只有固定答案；简化 web 环境覆盖面有限；无法进行真实 exploration 与 execution-based evaluation 。
- **OSWorld：**支持 Ubuntu 、 Windows 、 macOS ；允许鼠标、键盘、GUI 与 CLI ；可运行任意应用。
- **每个任务包含：**自然语言指令、初始系统状态 setup 、可复现 VM 、执行脚本 evaluator 。

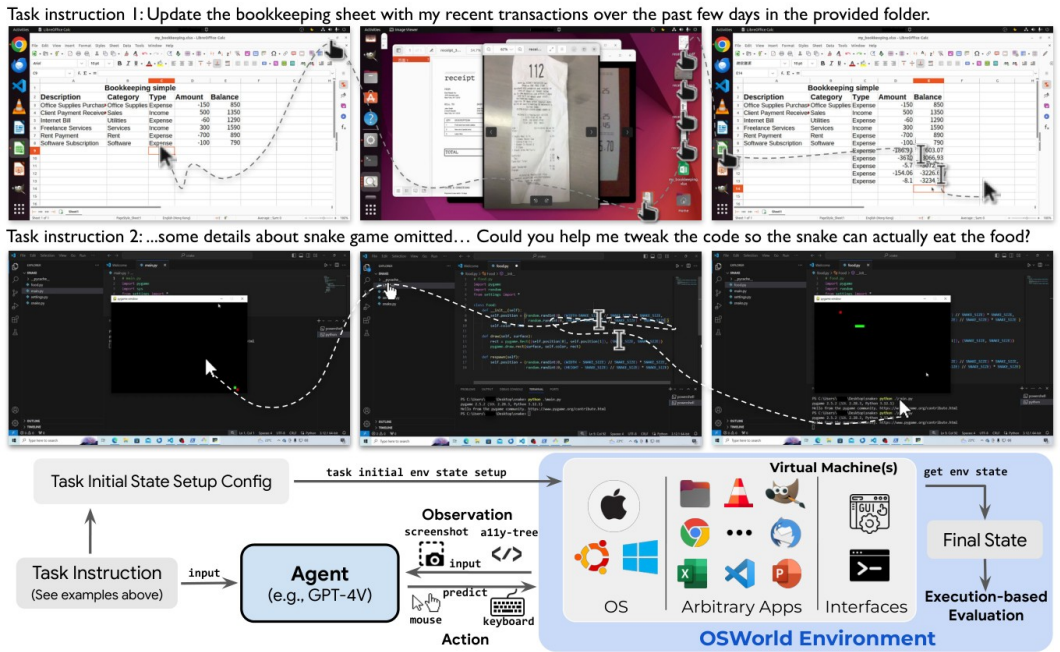
Config

```
{ "instruction": "Please update my bookkeeping sheet with
the recent transactions from the provided folder, detailing
my expenses over the past few days.",
  "config": [{"type": "download",
      "parameters": {"files": [
{"path": "/home/user/Desktop/my_bookkeeping.xlsx",
 "url": "https://drive.google.com/uc?id=xxxx"},
{"path": "/home/user/Desktop/receipt_0.jpeg",
 "url": "https://drive.google.com/uc?id=xxxx"},...]}},
    {"type": "open",
      "parameters": {  "path":
"/home/user/Desktop/my_bookkeeping.xlsx"}}],
   "evaluator": {"postconfig": [{"type": "activate_window",
      "parameters": {"window_name": "my_bookkeeping.xlsx -
LibreOffice Calc",... ],
    "result": {"type": "vm_file",
      "path": "/home/user/Desktop/my_bookkeeping.xlsx",
      "dest": "my_bookkeeping.xlsx"},
    "expected": {"type": "cloud_file",
      "path": "https://drive.google.com/uc?id=xxx",
      "dest": "my_bookkeeping_gold.xlsx" },
    "func": "compare_table",
    "options": {
      "rules": [{
          "type": "sheet_fuzzy",
          "sheet_idx0": "RNSheet1",
          "sheet_idx1": "ENSheet1",
          "rules": [ {"range": [ "A1:A8",... }]}]
}
```



论文原图： OSWorld architecture

369 个开放式计算机任务，覆盖文件、应用与跨应用 workflow



论文原图： OSWorld tasks

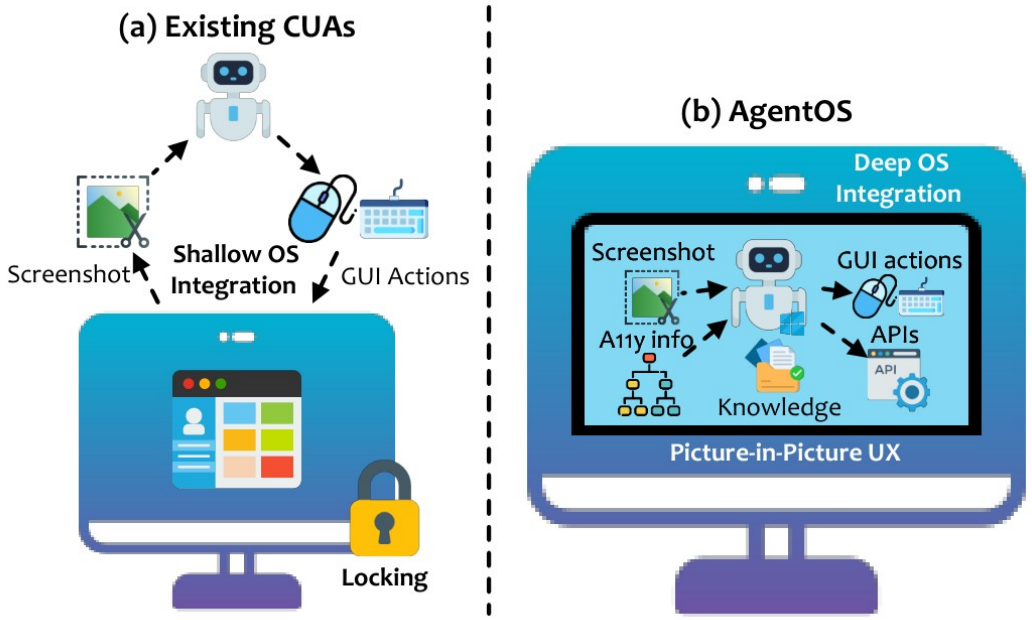
- **任务范围：** 浏览器、办公软件、图像、邮件、代码、OS 文件 I/O 、多应用协同。
- **评测：** 134 类定制 evaluator ，不依赖唯一操作序列，而检查最终环境状态。
- **结果：** 人类完成率 72.36% ； 当时最佳模型仅 12.24% ； 跨应用 workflow 最佳仅 6.57% 。
- **主要错误：** 点击坐标不准、重复动作、弹窗干扰、缺乏 GUI/domain knowledge 。

369	134	72.36%	12.24%
tasks	evaluators	human	then-best model

OSWorld 把 GUI Agent 从“预测动作”推进到“完成任务”

- **价值：**真实可执行、初态可复现、跨 OS/ 跨 app 、支持在线学习。
- **局限 1：**脚本 evaluator 仍可能把替代正确路径判为 false negative 。
- **局限 2：**环境启动与大规模 rollout 成本高。
- **局限 3：** benchmark 本身不提供更可靠的 Actor 架构。
- **过渡：**下一步不是只训练更大的 VLM ，而是把 CUA 变成深度集成 OS 的执行系统。

截图 + 模拟鼠标不足以支撑可扩展桌面自动化

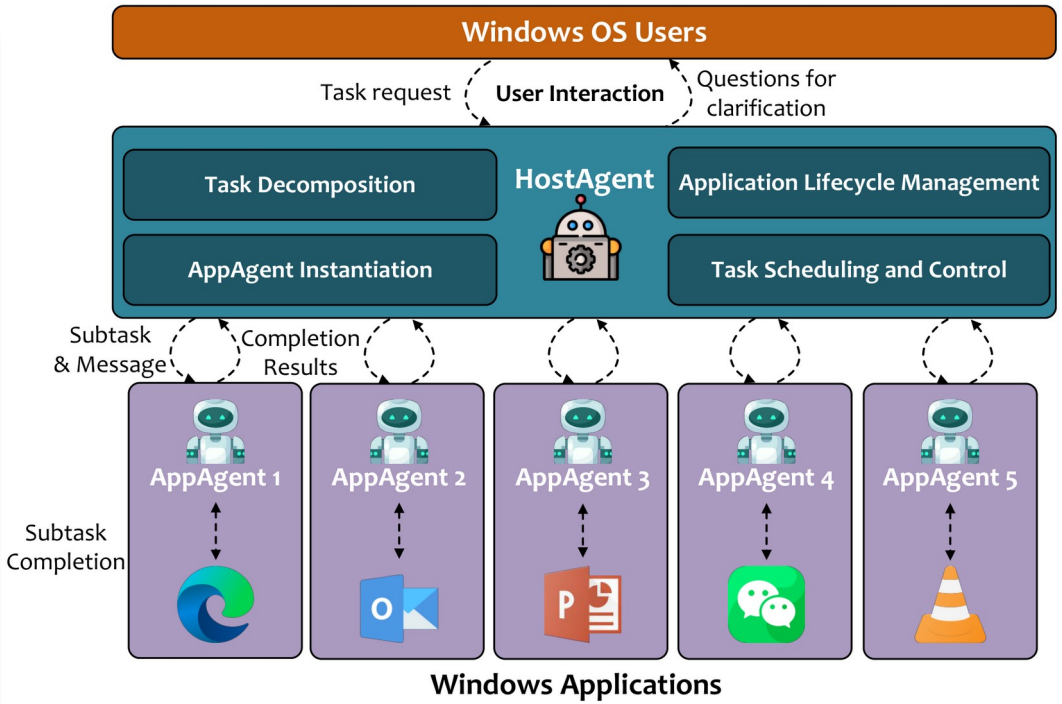


论文原图： UFO2 comparison

- **问题：**视觉输入冗余；缺少 UIA 、应用 API 与 process state ； 自动化占用主桌面并干扰用户。
- **UFO² 定位：** Windows multi-agent AgentOS ， 把 OS 能力、应用专用知识和执行控制嵌入 Agent loop 。
- **核心思想：**不是让一个通用模型直接操作所有应用，而是由中央协调器调度应用专家。

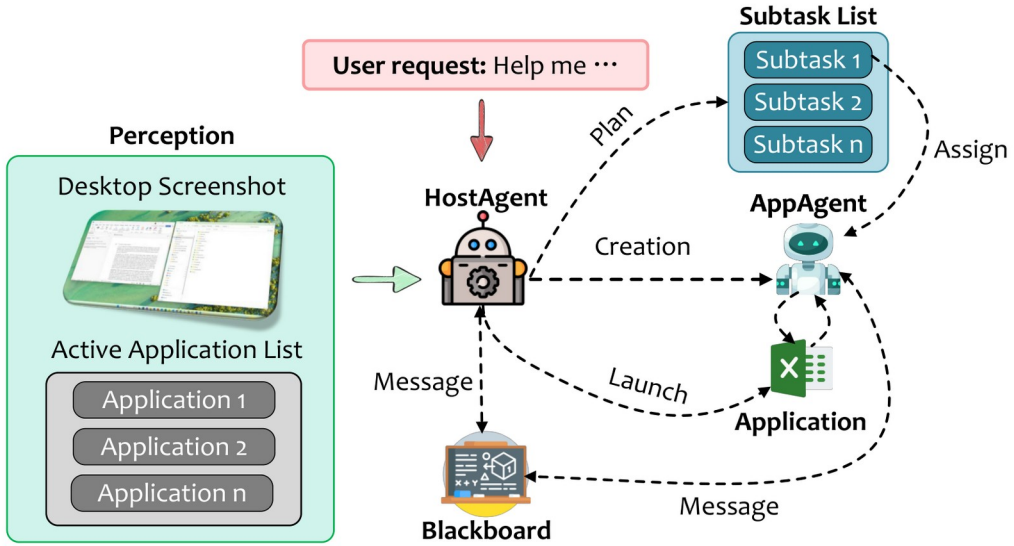
HostAgent 负责跨应用分解， AppAgent 负责应用内可靠执行

- **HostAgent：** 理解用户目标、分解跨应用 subtasks 、选择 / 调度 AppAgent 、汇总进度。
- **AppAgent：** 具备应用特定 API 、 domain knowledge 、 control detection 和 action execution 。
- **Session：** 维护 task 、 application 、 window 、 control 与 execution history 。
- **优势：** 模块化扩展；不同 app 可采用不同 observation/action 接口。



论文原图： UFO2 framework

能调用 API 时不必坚持“像人一样点鼠标”



论文原图： UFO2 HostAgent

- **GUI action：** 适合没有稳定接口、需要视觉定位或低层交互的控件。
- **Native/app API：** 适合结构化、批量、精确且对布局变化鲁棒的操作。
- **UFO²：** 在同一 plan 中混合 GUI 与 API，并由 AppAgent 根据状态选择。
  - **收益：** 减少不必要视觉推理、操作步数和布局脆弱性。
  - **风险：** API 权限更强，必须配套 safeguard 与 scope control 。