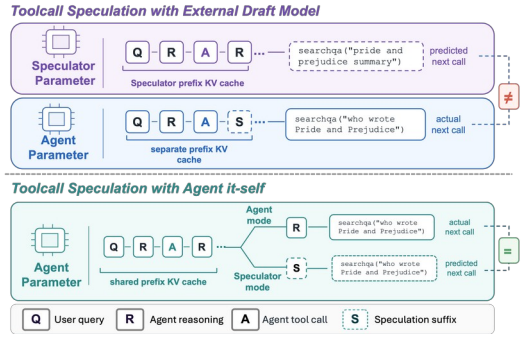
Speculate While You Reason

Teaching Agents to Predict Their Next Tool Call via Joint Agent–Speculator RL



arXiv:2607.25816

汇报人：张帅 | Agent 动作投机 Survey | 2026.08

小外部 Speculator 不一定既准又便宜，关键是与 Agent 对齐

背景 / 核心问题

- 外部小模型带来第二份权重 /KV，但仍常与 4B Agent 真实调用分布不一致。
- 通用 Agent 未被教过“从部分轨迹猜自己的下一调用”。
- Agent policy 会持续更新，预测目标也会漂移，离线旧轨迹很快过时。

主要贡献

1 Self-speculating agent

同一 πθ 以固定后缀切换 Agent / Speculator 模式，共享权重与 Prefix KV。

2 On-policy targets

从当前 Agent rollout 截取部分轨迹，实际下一调用作为目标。

3 Joint RL recipe

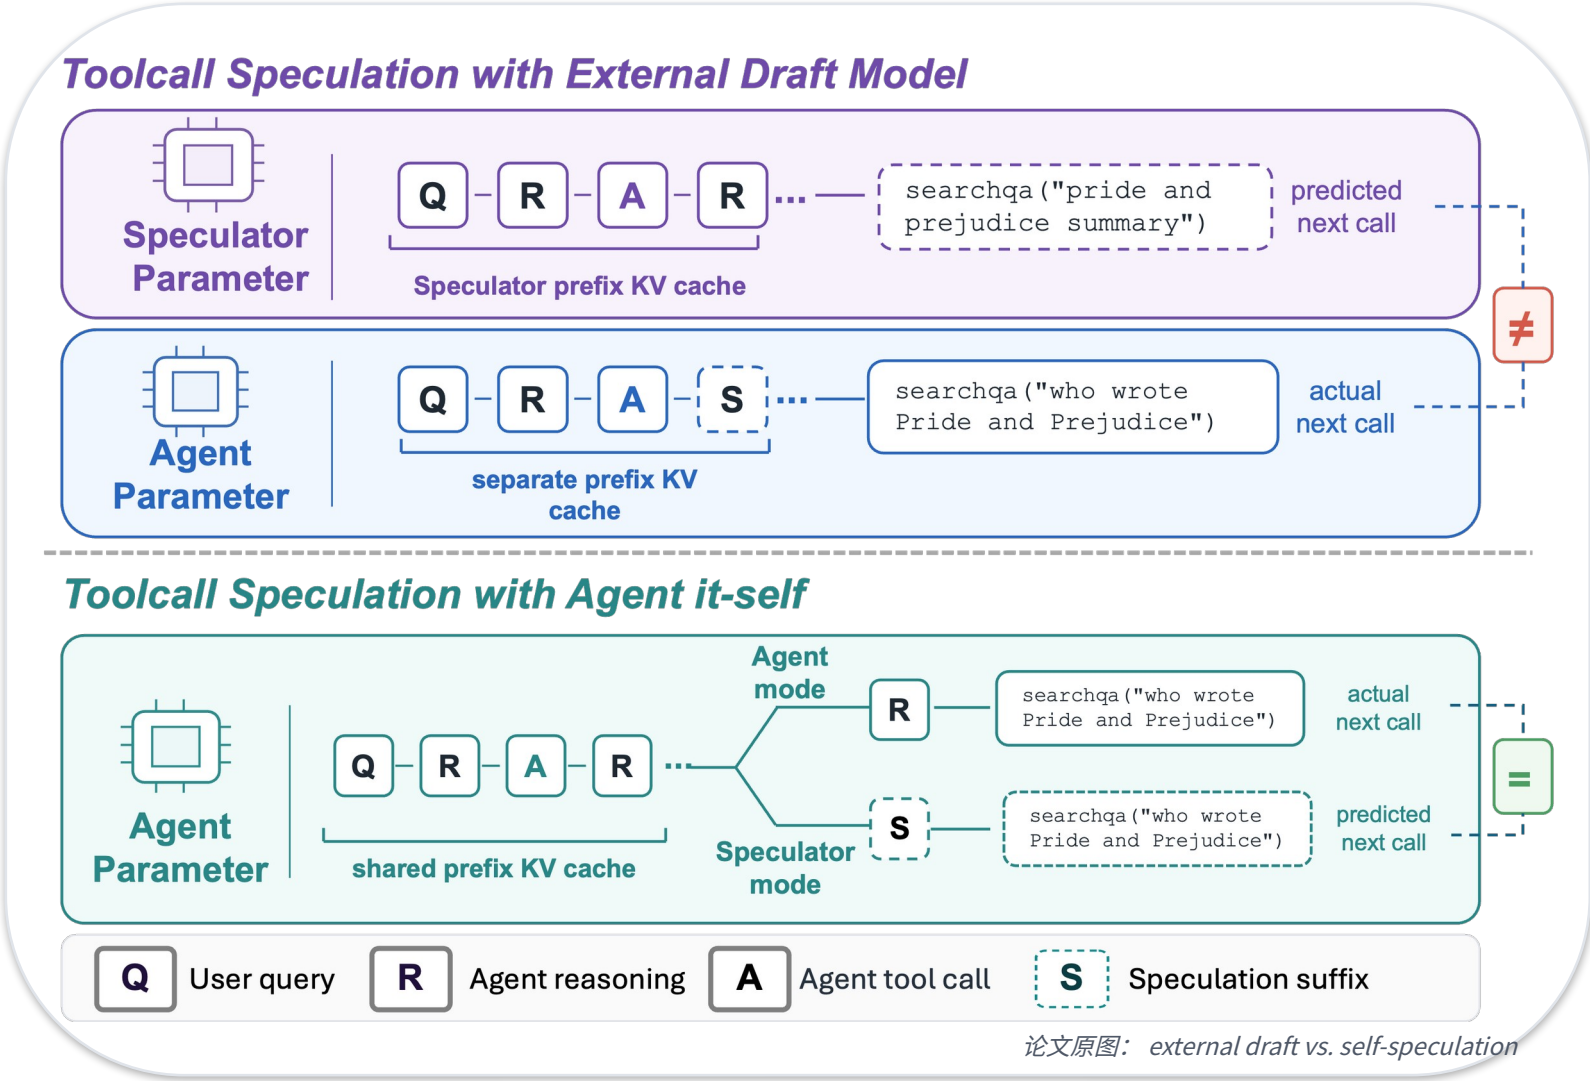
双模式 SFT + 4:8 交替 DAPO + 切换模式时重置 optimizer。

44.1→61.2

48.9→66.3

匹配训练域的 task success 保持；但训练修改了 Agent policy，不是严格轨迹无损。

“更小”的外部模型并不自然意味“更好”的 Speculator



论文原图： external draft vs. self-speculation

External small model

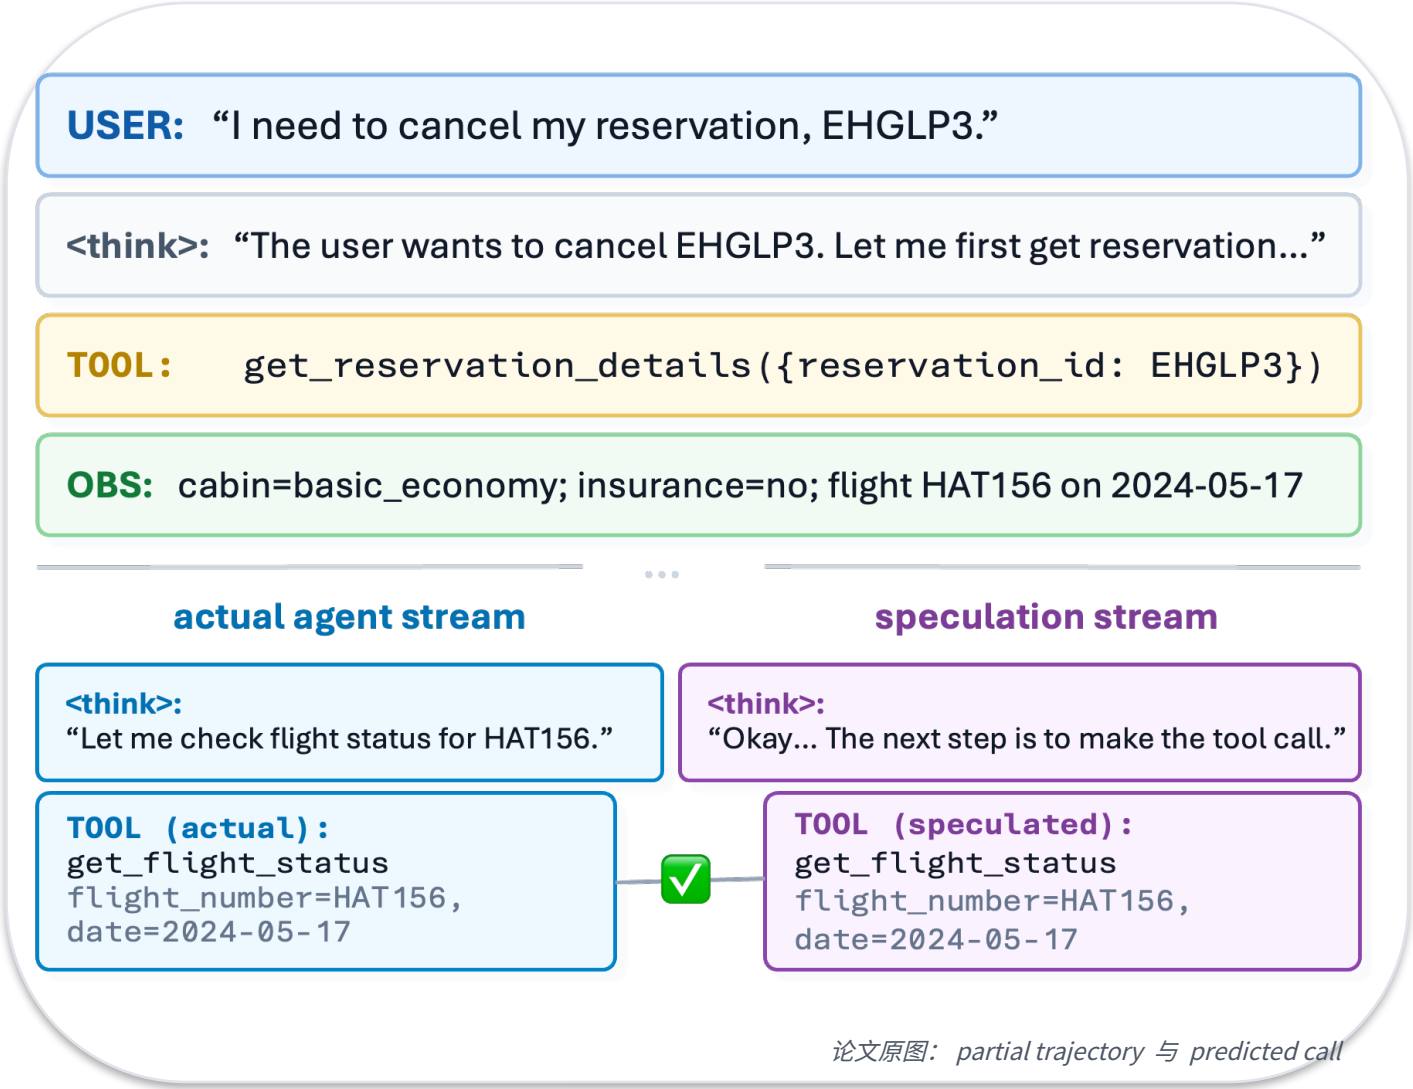
额外权重 + 独立 Prefix KV
预测分布与 Target 不一致
Qwen3 最强外部小模型平均 Hit@1 约 18.6

Same-model self-speculation

共享权重 + Prefix KV
与自身动作分布更接近
Qwen3-4B 未训练自投机平均 Hit@1 约 29.1

需学习： h_t → 下一结构调用 a_t

同一条 Agent rollout 同时提供任务学习和投机目标



论文原图：partial trajectory 与 predicted call

Step 1

用当前 πθ 生成完整 Agent rollout τ 。

Step 2

对每个工具轮 t 截取调用前缀 h_t 。

Step 3

追加固定投机后缀 s_sp ，触发 Speculator mode 。

Step 4

目标就是同一 rollout 中 policy 实际产生的 a_t 。

Agent：长 reasoning trajectory | Speculator：单个 structured call

部署需要完全匹配，训练则需要可学的稠密信号

Tool name

$$R_{name} = \mathbf{1}[\hat{n}_t = n_t]$$

工具名错误立即得 0，与“结果无法复用”一致。

Arguments

$$R_{args} = \frac{1}{|\text{keys}(\sigma_t)|} \sum_{k \in \text{keys}(\sigma_t)} \text{F1}(\hat{\sigma}_t[k], \sigma_t[k])$$

名字命中后按 key 做 macro token-F1，近似值获得局部信号。

Final reward

$$R_{sp} = R_{name} \cdot R_{args}$$

只有工具名正确，参数稠密奖励才生效。

工具名错

search → visit
R_sp = 0

工具名对，参数近似

query 字符串部分重叠
0 < R_sp < 1

完全命中

name + argument dictionary exact
Hit@1 = 1

训练标准 参数 token-F1 提供 partial credit，让 RL 有足够稠密的信号。

部署复用标准 解析后 tool name + 完整 argument dictionary 精确一致。

数据收集耦合，优化步骤分离：一个 policy 交替学两个目标

Joint Agent–Speculator RL

SFT warmup

成功 Agent 轨迹 + 部分轨迹投机样本

4 × Agent updates

R_ag： 最终任务奖励
DAPO grouped advantages

8 × Spec. updates

R_sp： 下一工具奖励
DAPO grouped advantages

每次模式切换重置 optimizer state

1 稳定技巧 1

先 SFT 建立两种正确输出格式。

2 稳定技巧 2

切换时清除 momentum / adaptive statistics 干扰。

3 稳定技巧 3

Agent reward 惩罚无意义重复工具调用。

不将 R_ag 和 R_sp 粗暴线性相加后同步更新

联合 RL 把自投机从“可用起点”提高到“更高严格命中率”

Base → SFT → Joint RL

Qwen3-4B

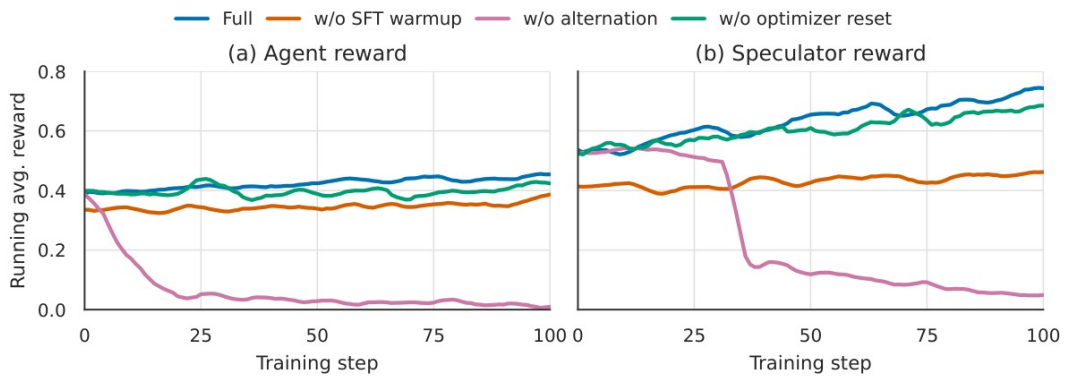
29.1	44.1	61.2
Base	SFT	RL

Task success: 26.4 → 26.6 → 27.7

Qwen3.5-4B

33.2	48.9	66.3
Base	SFT	RL

Task success: 49.0 → 49.2 → 50.6



论文原图： reward ablation trends

移除 SFT warmup 、 optimizer reset 或 alternating schedule ，都会使 Agent / Speculator reward 更弱或更不稳定。

该方法优化 Speculator–Agent 对齐，代价是改变 Agent 本身

三句话带走

01

架构：同一模型双模式，消除额外权重并共享 Prefix KV 。

02

学习：下一工具目标来自当前 Agent 新鲜 rollout ，交替 RL 维持两种行为。

03

结果：严格 Hit@1 大幅上升，匹配训练域的 task success 保持。

适用边界 / 限制

- 不是 Speculative Actions 意义下的严格轨迹无损： RL 直接改了 Agent policy 。
- 跨域 Hit@1 可能上升，但任务成功率不总是稳定，仍敏感于训练分布。
- 主要证据是 Hit@1 与 Agent 质量；全栈 E2E 延迟 / 资源证据不如 PASTE 、 SPORK 完整。

Survey 技术链中的位置

SPORK
训练免费的同模型 probe
↓
Joint RL
主动训练 Agent 学会预测自己