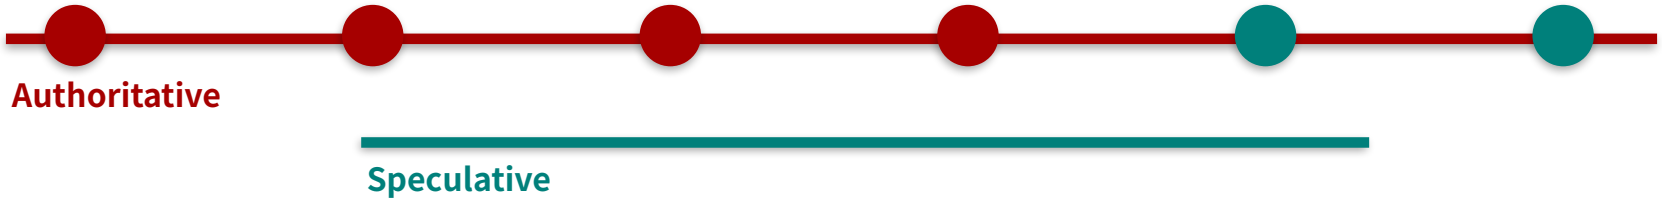
PASTE

Parallelizing Tool Execution and LLM Generation for Low-Latency Agent Serving



Yifan Sui et al. · arXiv:2603.18897

汇报人：张帅 | Agent 动作投机 Survey | 2026.08

Agent Serving 的关键路径不只是 LLM，工具占 45%–57%

背景 / 核心问题

- LLM 生成 → 工具调用 → 等待 → LLM 恢复，语义依赖被实现成物理串行。
- Deep research、coding、AI4Science 中，工具执行占 E2E 延迟 45%–57%。
- 要隐藏 exposed tool time，必须在 LLM 尚未输出时得到具体 (tool, args)。

主要贡献

1 Pattern Analyzer

抽取重复控制流 + 隐式数据流，实例化未来调用。

2 Tool Scheduler

准入、隔离、确认 / 提升 / 丢弃，权威调用优先。

3 LLM–Tool Co-Scheduler

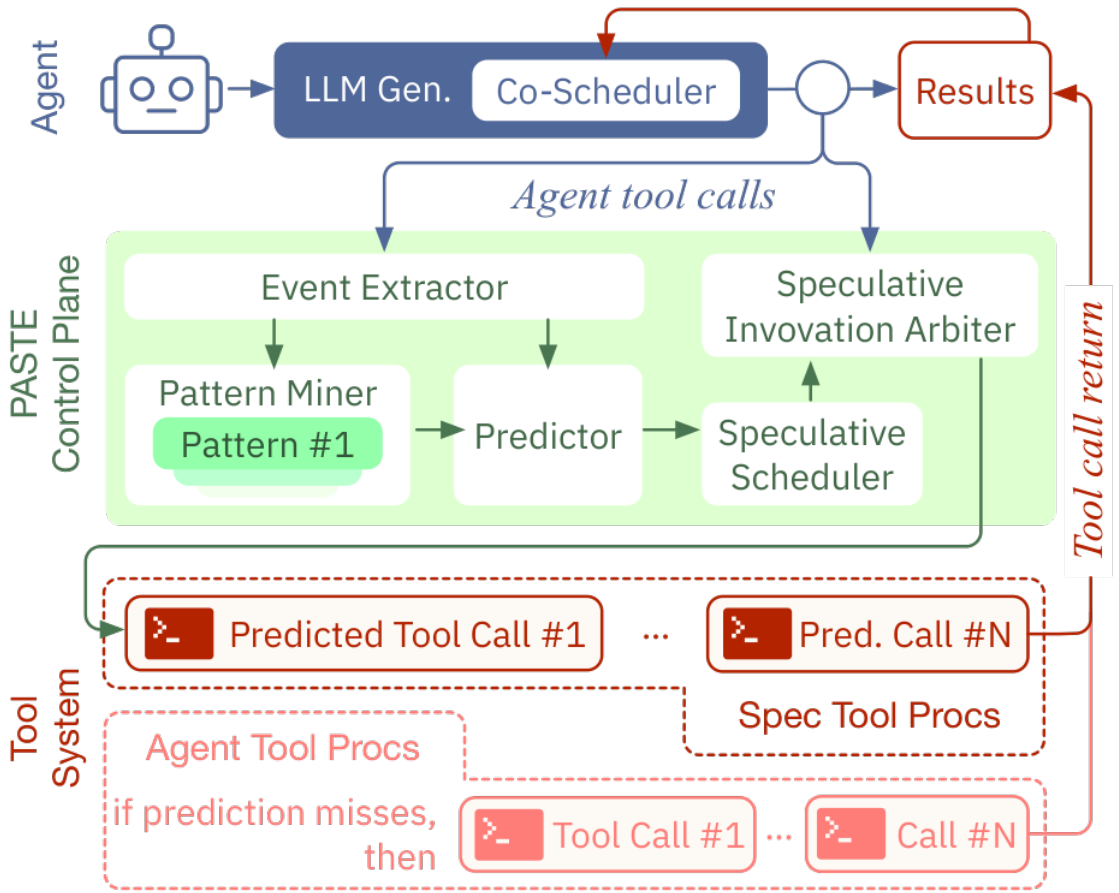
节奏化 returning sessions，不让工具侧收益变成 GPU 排队。

-43.5%

1.8×

预测命中 ≠ E2E 一定变快；必须联合考虑工具与 LLM 两个资源域。

PASTE 不是单一预测器，而是三个闭环调度组件



论文原图： PASTE system overview

1 Mining

历史 session 提取稳定工具转移和参数派生规则。

2 Instantiation

用当前上下文填充 pattern ，得到具体 (tool,args) 。

3 Speculation

选择性提前执行，结果先进隔离区。

4 Match

权威调用到达时规范化比较 name+args 。

5 Pacing

使用工具侧信号控制 session 返回 LLM 的节奏。

未确认结果对 Agent 不可见

从“经常这样做”到“现在可以提前执行”

1 控制流挖掘

Search → Visit
Edit → Test
Grep → FileEditor

2 数据流学习

下一工具参数来自上一输出或当前 session 字段。

3 在线实例化

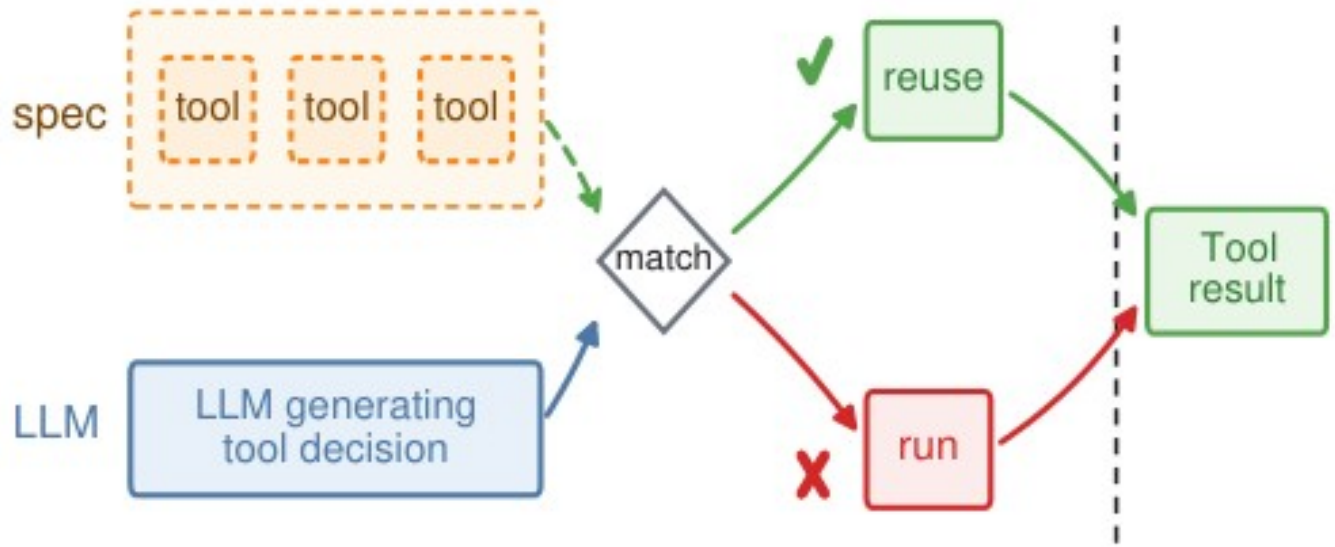
只当所需输入已出现，才生成具体 tool+args 。

4 调度器仲裁

多个 pattern 冲突时，按收益、置信度和资源准入。

Search("DSP paper") 已返回 URL → 从当前上下文抽取 URL → LLM 还在生成时预先执行 Visit(url)

提前运行不等于提前提交：完整的投机生命周期



论文原图： speculative tool execution

Candidate — Admitted — Running — Reuse — Promote — Discard

准入

预计可隐藏工具时间 > 调度与资源机会成本。

隔离

结果进 speculative store，不写 authoritative session state。

严格匹配

工具名 + 规范化参数一致才能 reuse；同一运行 job 可 promote。

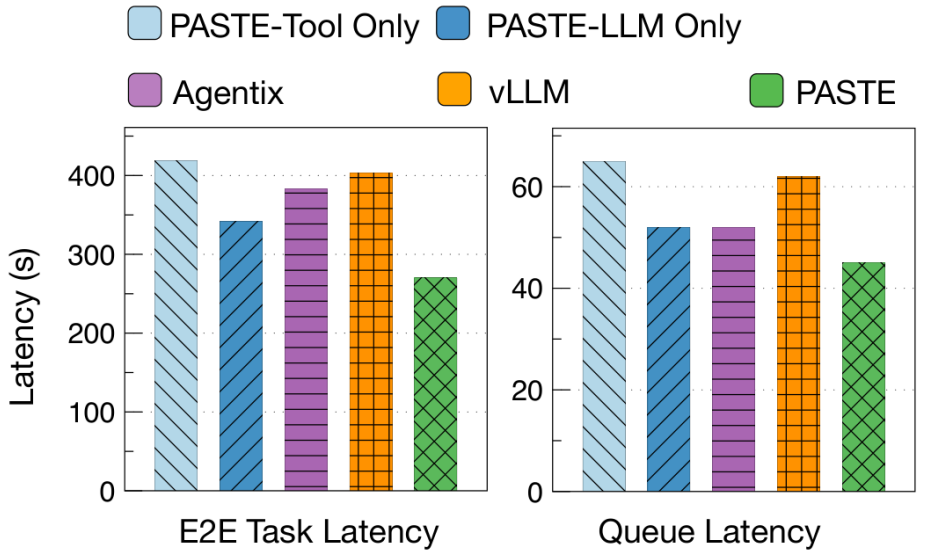
安全：优先只读 / 幂等 / 可隔离工具；有副作用工具需显式策略、 sandbox 或非变更版本。

工具侧变快后，为什么 E2E 反而可能变慢?

工具更早完成 — Returning sessions 突然增加 — GPU/KV 压力上升 — Queueing 抵消收益

LLM–Tool Co-Scheduler

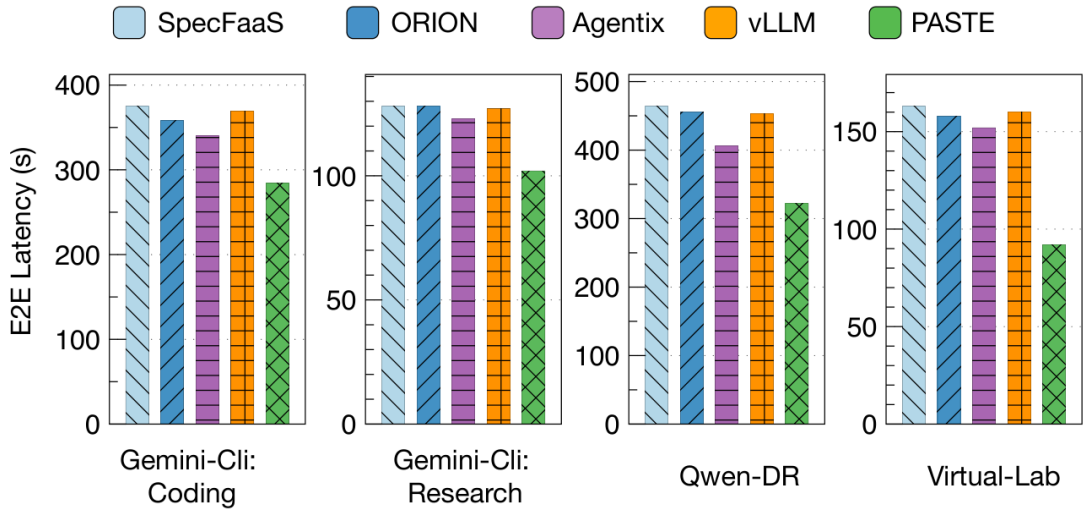
- 观测工具完成、 reuse/promotion 和已隐藏时间。
- 联合观测 active requests 、 decode batch 、 context/KV pressure 。
- GPU 过载时限制同时恢复数；利用不足时快速放行。
- 目标：将工具侧 overlap 真正转化为 task E2E 收益。



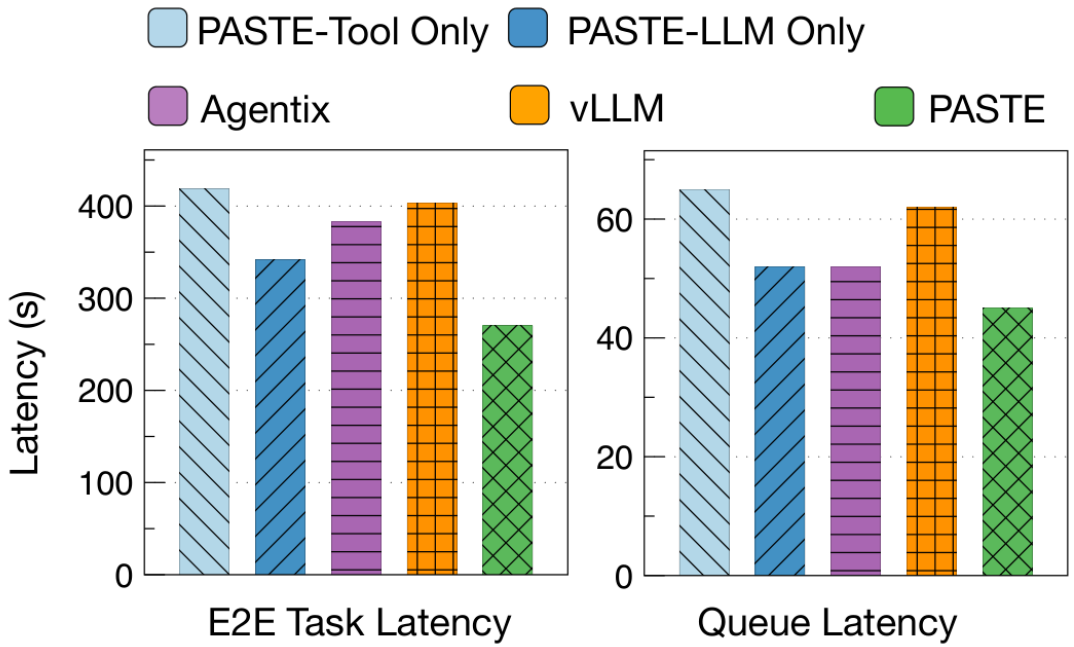
论文消融： Tool-only / LLM-only / Full PASTE

Tool-only 不是完整解法； Agent Serving 的目标是跨 LLM 与 Tool 两个资源域的 task E2E 。

全栈协同才能把工具侧 overlap 转化为 E2E 收益



E2E latency vs. serving baselines



Tool-only / LLM-only / Full PASTE

-43.5%
平均 E2E （最多）

-55.4%
p99 （最多）

1.8×
工具延迟改善

Tool-only： LLM queue 65s / E2E 419s
Full PASTE： 45s / 270s

PASTE 把“动作投机”推进为“ Agent Serving 全栈并行化”

三句话带走

01

预测来源：重复轨迹中的控制流 + 数据流，不额外调用 LLM 。

02

无损核心：观测式预测、结果隔离、权威优先、严格 name+args 。

03

系统核心：工具侧提前执行必须与 LLM 侧 pacing 一起设计。

适用边界 / 限制

- 依赖重复 Agent 轨迹和可从已知上下文提取的具体参数。
- 低频工具、开放参数和长尾 pattern 收益有限。
- 不可撤销的外部副作用工具不能直接投机执行。

Survey 技术链中的位置

Speculative Actions
通用执行语义
↓
PASTE
预测 + 工具执行 + 全栈调度