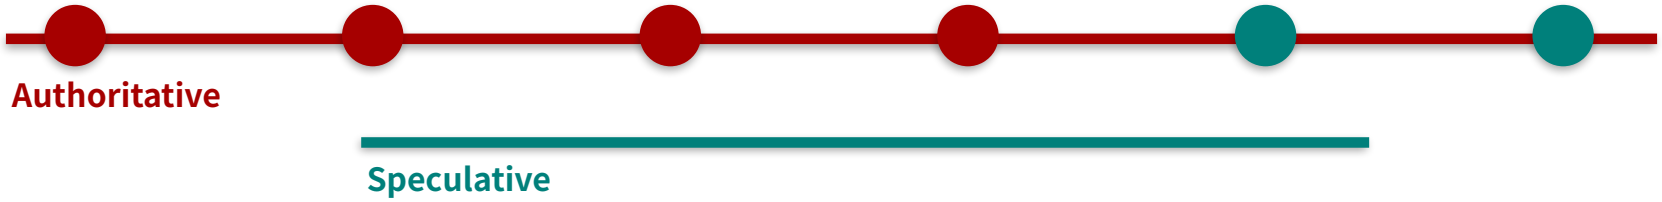
PASTE

Parallelizing Tool Execution and LLM Generation for Low-Latency Agent Serving



Yifan Sui et al. · arXiv:2603.18897

汇报人：张帅 | Agent 动作投机 Survey | 2026.08

Agent Serving 的关键路径不只是 LLM，工具占 45%–57%

背景 / 核心问题

- LLM 生成 → 工具调用 → 等待 → LLM 恢复，语义依赖被实现成物理串行。
- Deep research、coding、AI4Science 中，工具执行占 E2E 延迟 45%–57%。
- 要隐藏 exposed tool time，必须在 LLM 尚未输出时得到具体 (tool, args)。

主要贡献

1 Pattern Analyzer

抽取重复控制流 + 隐式数据流，实例化未来调用。

2 Tool Scheduler

准入、隔离、确认 / 提升 / 丢弃，权威调用优先。

3 LLM–Tool Co-Scheduler

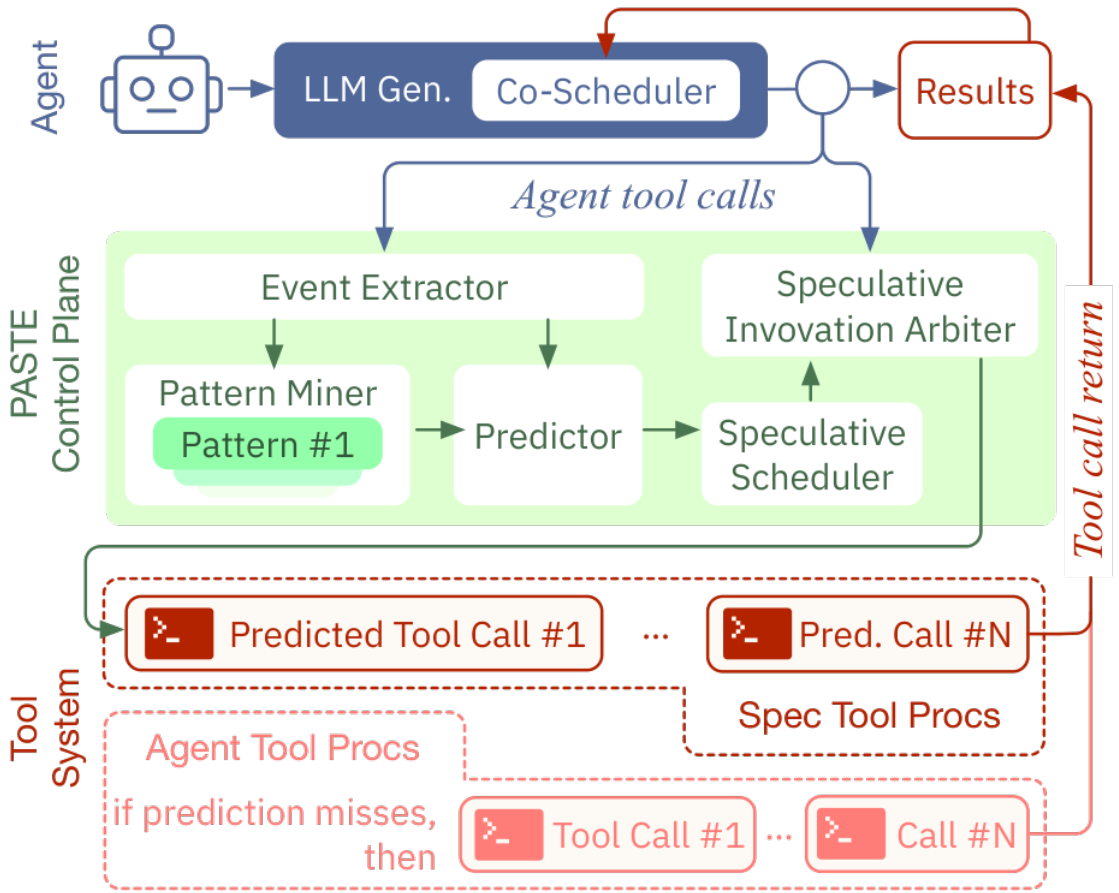
节奏化 returning sessions，不让工具侧收益变成 GPU 排队。

-43.5%

1.8×

预测命中 ≠ E2E 一定变快；必须联合考虑工具与 LLM 两个资源域。

PASTE 不是单一预测器，而是三个闭环调度组件



论文原图： PASTE system overview

1 Mining

历史 session 提取稳定工具转移和参数派生规则。

2 Instantiation

用当前上下文填充 pattern ，得到具体 (tool,args) 。

3 Speculation

选择性提前执行，结果先进隔离区。

4 Match

权威调用到达时规范化比较 name+args 。

5 Pacing

使用工具侧信号控制 session 返回 LLM 的节奏。

未确认结果对 Agent 不可见

从“经常这样做”到“现在可以提前执行”

1 控制流挖掘

Search → Visit
Edit → Test
Grep → FileEditor

2 数据流学习

下一工具参数来自上一输出或当前 session 字段。

3 在线实例化

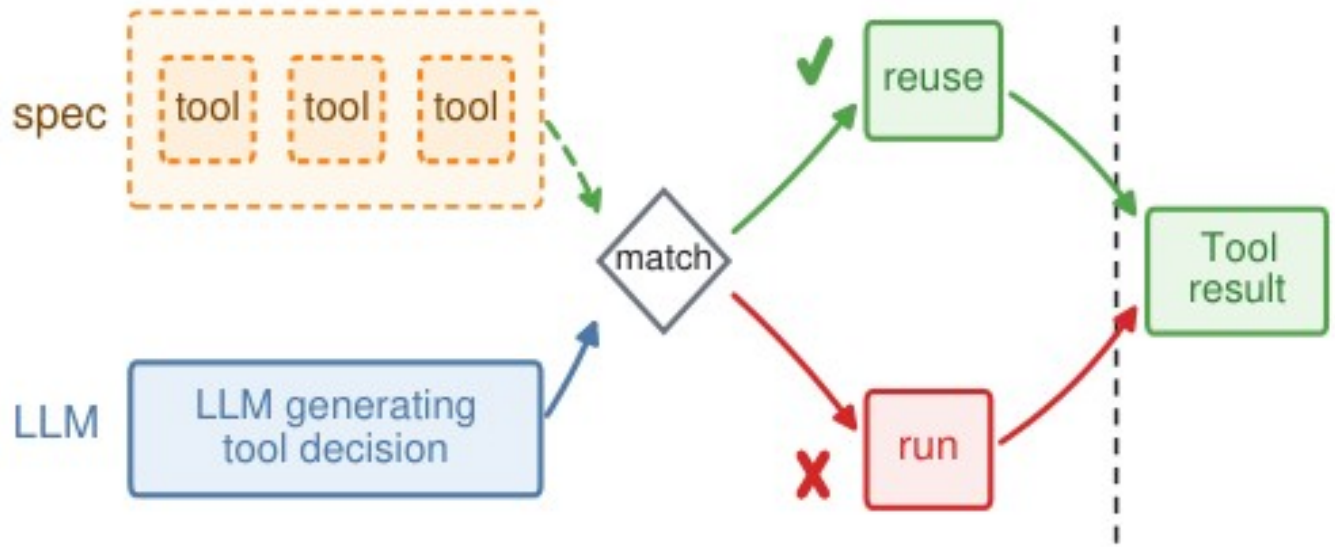
只当所需输入已出现，才生成具体 tool+args 。

4 调度器仲裁

多个 pattern 冲突时，按收益、置信度和资源准入。

Search("DSP paper") 已返回 URL → 从当前上下文抽取 URL → LLM 还在生成时预先执行 Visit(url)

提前运行不等于提前提交：完整的投机生命周期



论文原图： speculative tool execution

Candidate — Admitted — Running — Reuse — Promote — Discard

准入

预计可隐藏工具时间 > 调度与资源机会成本。

隔离

结果进 speculative store，不写 authoritative session state。

严格匹配

工具名 + 规范化参数一致才能 reuse；同一运行 job 可 promote。

安全：优先只读 / 幂等 / 可隔离工具；有副作用工具需显式策略、 sandbox 或非变更版本。