SPORK

Self-Speculative Forking to Accelerate Agentic LLM Inference



Huajun Bai et al. • arXiv:2607.03333

汇报人：张帅 | Agent 动作投机 Survey | 2026.08

外部 Speculator 的成本，也是 Agent 投机的系统瓶颈

背景 / 核心问题

- 外部小模型需要第二份权重 /KV cache，且常与 Actor 的真实调用分布不一致。
- 历史 pattern 对长尾工具和少见参数容易失效。
- 研究问题：运行中的 LLM 能否足够早、足够准且失败后可回收地预测自己?

主要贡献

1. **D1 | Prefix-KV Fork**

首 token 后强制工具前缀，缓存命中将 probe 约 1.6s 降到 0.35s 。

2. **D2 | Confidence Gate**

用 probe 自身 tool-name logprob，选择最早可信提交时刻。

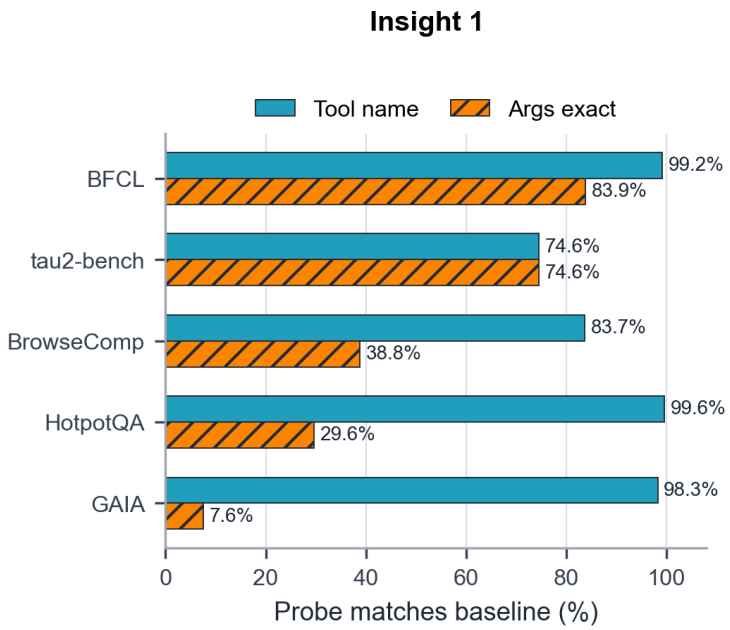
3. **D3 | Token Reuse**

严格拒绝时，把共享工具调用前缀当作 token 草稿。

Training-free self-speculation：同一 Actor 、共享 Prefix KV 、工具级严格匹配。

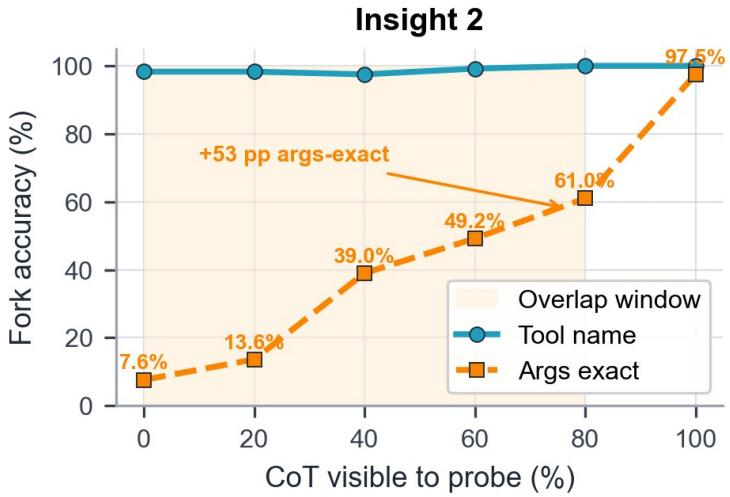
同一模型确实“早知道、知道何时可信、失败也不全浪费”

Insight 1 ｜早知道工具名



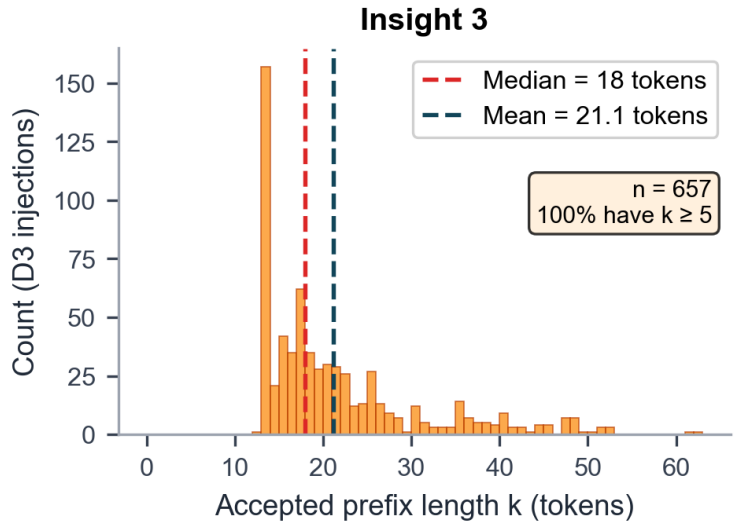
tool-name 74.6%–99.6%
args exact 7.6%–83.9%

Insight 2 ｜信心随 CoT 上升



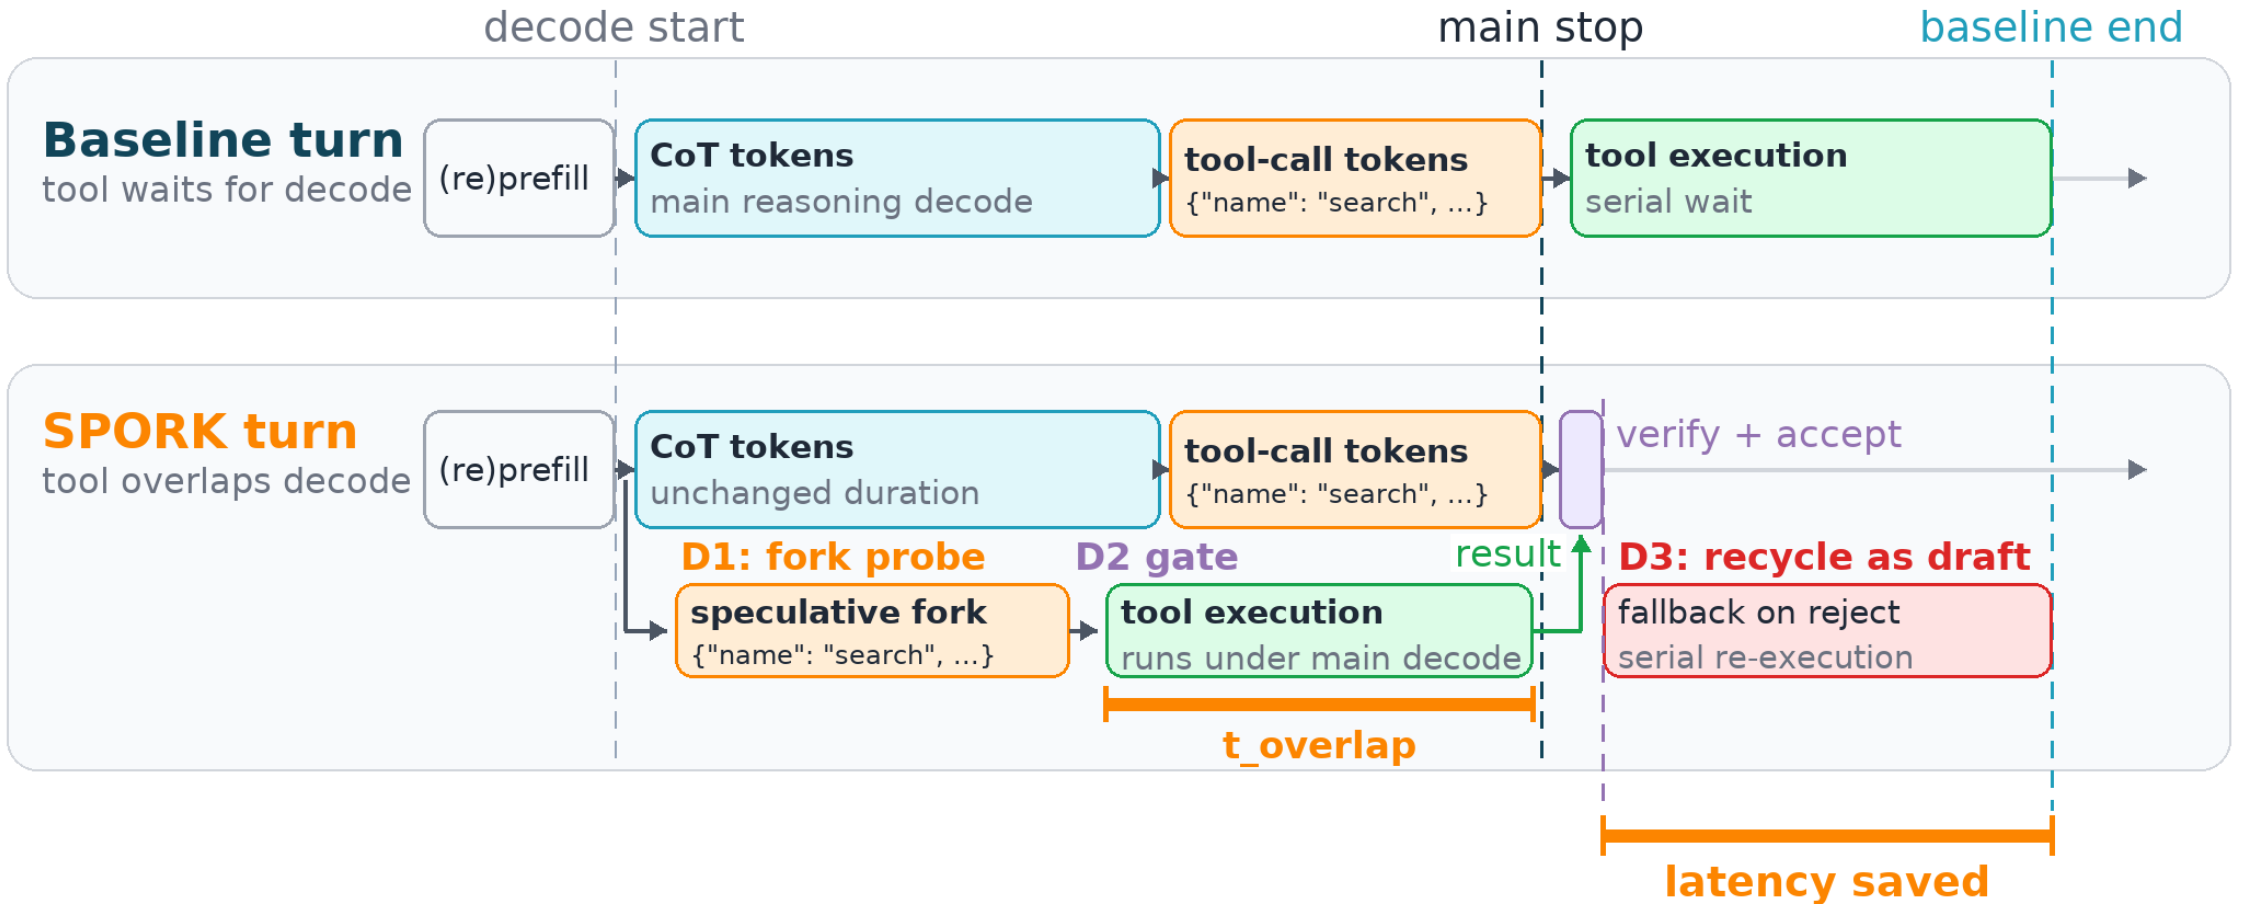
GAIA args exact
7.6% → 97.5%

Insight 3 ｜拒绝仍有前缀



中位 18 tokens
P25 = 14 tokens

SPORK 的“分叉—门控—严格验收—前缀回收”



论文原图： SPORK method overview

D1 先把“多跑一次模型”的前缀开销压到足够低

$$\text{Speedup} = \frac{T_{base}}{T^{*}_{base} - \alpha t_{overlap} + T_{oh}}$$

Break-even $\alpha\, t_{overlap} \geq T_{oh}$

α

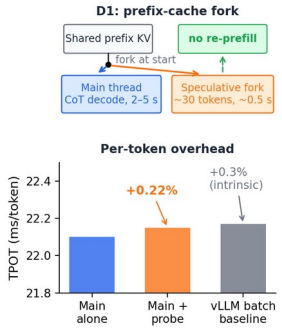
严格命中并接受已执行工具的 turn 比率。

t_overlap

工具执行与主生成真正重叠的时间。

T_oh

probe prefill/decode 以及对主流的干扰。



D1 的实际效果

等 main 第一个 token 后再发 probe，前缀 KV 已入缓存。
prefill 1.3s → 0.05s
整个 probe 1.6s → 0.35s
main TPOT 干扰约 +0.22%